

Analisis Pola Kecelakaan Lalu Lintas Menggunakan Algoritma Decision Tree Berdasarkan Ekstraksi Informasi dari Berita Online Menggunakan Named Entity Recognition (NER)

(Studi Kasus: Tol di Provinsi Jawa Barat)

(Analysis of Traffic Accident Patterns Using Decision Tree Algorithm Based on Information Extraction from Online News Using Named Entity Recognition (NER))

Hardi Dwi Susanto*, Budi Yuniarto

Program Studi Komputasi Statistik, Politeknik Statistika STIS
Jalan Otto Iskandardinata No. 64C, Jakarta Timur, Indonesia 13330
E-mail: 221910754@stis.ac.id

ABSTRAK

Jalan tol sebagai jalan bebas hambatan tidak membuat jalan tol terbebas dari kecelakaan lalu lintas. Di Provinsi Jawa Barat, terdapat total 20 ruas tol dengan panjang ruas tol mencapai 521,15 km pada 2020. Tol Cipali adalah salah satu ruas dengan fatalitas tertinggi di dunia. Penanggulangan kecelakaan lalu lintas penting dilakukan sebagai upaya untuk mengurangi kejadian kecelakaan lalu lintas. Namun, data *official* mengenai kecelakaan lalu lintas di jalan tol oleh lembaga resmi tidak tersedia secara rinci, sehingga digunakan sumber data alternatif seperti berita *online*. NER dengan Bi-LSTM-CNN dimanfaatkan untuk melakukan ekstraksi data kecelakaan. Hasil dari ekstraksi berita dianalisis dengan membuat aturan keputusan untuk mengetahui pola kecelakaan yang terjadi. Aturan keputusan ini berupa *decision tree* dengan dataset yang menggunakan data tiga tol dengan fatalitas tertinggi dengan fitur imputasi *mode by concept* sebagai metode penanganan *missing value* dan jalan tol sebagai atribut, menghasilkan nilai *f1-score* sebesar 67,76% dan nilai akurasi sebesar 75,49%.

Kata kunci: kecelakaan lalu lintas, jalan tol, pola kecelakaan, *named entity recognition*, *decision tree*

ABSTRACT

Toll roads as freeways do not make toll roads free from traffic accidents. In 2020, West Java Province had a total of 20 toll roads spanning a length of 521,15 km. The Cipali Toll Road is one of the sections with the highest fatalities in the world. Prevention of traffic accidents is important as an effort to reduce the incidence of traffic accidents. However, official data regarding traffic accidents on toll roads by official agencies is not available in detail, so alternative data sources such as online news are used. NER with Bi-LSTM-CNN is used to extract accident data. The results of news extraction are analyzed by making decision rules to determine the pattern of accidents that occur. This decision rule is in the form of a decision tree with a dataset that uses data from three toll roads with the highest fatality with the mode by concept imputation feature as a missing value handling method and toll roads as attributes, resulting in an *f1-score* value of 67,76% and an accuracy value of 75,49 %.

Keywords: traffic accident, toll road, accident pattern, *named entity recognition*, *decision tree*

PENDAHULUAN

Jalan tol adalah jalan bebas hambatan yang merupakan bagian sistem jaringan jalan dan sebagai jalan nasional yang penggunaannya diwajibkan membayar (UU No 2 Tahun 2022). Tol adalah akronim dari *Tax on Location* yang merujuk pada penerapan tarif pada pengguna jalan melalui pintu pemberhentian di jalan tol. Penyelenggaraan jalan tol bertujuan untuk memperlancar lalu lintas antar daerah dengan memberikan keuntungan bagi pengguna seperti penghematan biaya operasi kendaraan dan waktu tempuh dibanding apabila melalui jalan non tol. Sebagai jalan bebas hambatan, jalan tol diharapkan memberikan perbedaan yang nyata baik kualitas maupun performanya bila dibandingkan dengan jalan umum atau jalan biasa. Dengan adanya fasilitas-fasilitas pendukung yang ada di jalan tol, seharusnya jalan tol memiliki tingkat keamanan dan kenyamanan yang lebih baik sehingga peristiwa kecelakaan dapat dihindarkan. Namun, seringkali justru membuat pengguna lengah dan malah membahayakan keselamatan diri sendiri maupun pengguna lain (Mulia & Widowati, 2021). Status jalan tol sebagai jalan bebas hambatan tidak membuat jalan tol terbebas dari kecelakaan lalu lintas.

Kecelakaan di jalan tol dapat disebabkan oleh berbagai hal atau kendala. Kecelakaan yang terjadi sering kali tidak hanya disebabkan oleh satu faktor saja, melainkan karena interaksi antar faktor penyebab kecelakaan (Gloria, 2021). Penyebab kecelakaan di Indonesia paling besar disebabkan oleh faktor manusia mencapai 61%, yakni terkait kemampuan dan karakter pengemudi, faktor prasarana dan lingkungan sebesar 30%, dan yang terakhir adalah faktor kendaraan terkait dengan pemenuhan persyaratan layak jalan, yaitu sebesar 9% (BPJT, 2022). Berdasarkan data BPJT (2022), terdapat 2.626 kasus kecelakaan di jalan tol pada tahun 2019. Kemudian mengalami kenaikan yang cukup tinggi pada tahun 2020 sebesar 14,88% menjadi 3.907 kasus kecelakaan dan naik kembali pada 2021 sebesar 2,07% menjadi 3.988 kasus kecelakaan. Jika ditata-rata, terdapat 2,16 kejadian per kilometer pada tahun 2019. Angka tersebut naik menjadi 2,52 kejadian per kilometer pada tahun 2020 dan turun menjadi 1,62 kejadian per kilometer pada tahun 2021. Namun, angka kematian akibat kecelakaan di jalan tol secara agregat terus menurun.

Di Provinsi Jawa Barat, terdapat total 20 ruas tol dengan panjang ruas tol mencapai 521,15 km pada 2020 dari total ruas tol yang beroperasi di Indonesia sepanjang 2.334,17 km. Tol Cikopo-Palimanan (Cipali) adalah salah satu ruas tol terpanjang di Indonesia, dengan total ruas tol mencapai 116 km. Tol dengan ruas yang panjang berpotensi menyebabkan pengemudi lelah sehingga membahayakan jika dilalui dalam kecepatan tinggi (Setyabudi, 2021). Menurut Kementerian Perhubungan (Kemenhub), ruas Tol Cipali memiliki angka kecelakaan lalu lintas kecelakaan dengan fatalitas tertinggi di dunia (Rayanti, 2022). Terdapat setidaknya satu korban jiwa per kilometer atau terdapat sekitar 36 kejadian kecelakaan di Tol Cipali setiap bulannya. Sementara pada publikasi BPJT, Tol Cipali adalah tol dengan korban meninggal dunia terbanyak karena kecelakaan lalu lintas, terdapat 70 korban meninggal dunia pada 2020 dan 52 korban meninggal pada 2021. Standar aman gap kecepatan antar kendaraan adalah 30 km/jam, sementara di Tol Cipali gap kecepatannya mencapai 100 km/jam.

Penanggulangan kecelakaan lalu lintas penting dilakukan sebagai upaya untuk mengurangi kejadian kecelakaan lalu lintas. Agar mendapat solusi yang tepat, diperlukan informasi yang lengkap mengenai kecelakaan lalu lintas yang terjadi. Namun, data *official* mengenai kecelakaan lalu lintas di jalan tol oleh lembaga resmi tidak tersedia secara rinci. Dalam hal ini, berita *online* dapat dimanfaatkan sebagai sumber data alternatif untuk melengkapi keterbatasan data yang ada. Dalam teks berita *online* terdapat informasi mengenai kecelakaan lalu lintas yang dapat diambil menggunakan *Information Extractions* (IE) atau ekstraksi informasi. Ekstraksi informasi adalah suatu bidang ilmu untuk pengolahan bahasa alami dengan cara mengubah teks tidak terstruktur menjadi suatu informasi dalam bentuk yang terstruktur (Susanti & Mustofa, 2015). Hasil dari ekstraksi berita kemudian diolah dan dilakukan analisis dengan menarik kesimpulan berupa aturan keputusan untuk mengetahui apakah kejadian kecelakaan akan menyebabkan korban meninggal atau tidak. Hal ini didasarkan pada kecelakaan lalu lintas, dampak atau kerugian seperti korban meninggal dunia perlu dihindari.

METODE

Data dan Sumber Data

Data yang digunakan dalam penelitian ini, yaitu data yang diperoleh dari hasil *scraping* pada situs web detik.com yang kemudian diekstraksi untuk diambil informasi yang diperlukan. Situs berita tersebut dipilih karena terdapat cukup banyak artikel terkait kecelakaan lalu lintas di jalan tol. Artikel teks berita yang diambil merupakan berita terkait kecelakaan lalu lintas yang terjadi di jalan tol di Provinsi Jawa Barat, dengan tanggal terbit mulai dari 1 Januari 2020 hingga 31 Desember 2022.

Data artikel berita *online* yang didapatkan dari hasil *scraping* adalah sebanyak 5403 artikel berita tentang kecelakaan lalu lintas di Jalan Tol di Jawa Barat. Selanjutnya, pada data tersebut dilakukan *preprocessing* berupa *data cleaning*, *text preprocessing*, dan *filtering*. Data hasil *filtering* adalah sebanyak 564 artikel berita yang kemudian pada data tersebut dilakukan ekstraksi informasi.

Ekstraksi informasi dilakukan dengan memanfaatkan salah satu metode *deep learning*, yaitu *Named Entity Recognition* (NER) dengan *Bidirectional Long Short Term Memory* (Bi-LSTM) yang dikombinasikan dengan *Convolutional Neural Network* (CNN). Bi-LSTM-CNN mengkombinasikan *Bidirectional Recurrent Neural Network* dengan LSTM untuk mentransformasikan kata sesuai karakteristiknya menjadi sebuah entitas nama secara dua arah menggunakan jaringan LSTM maju dan jaringan LSTM mundur, serta CNN yang mampu memodelkan informasi hingga level karakter suatu kata (Chiu & Nichols, 2016). Atribut-atribut berita yang diperlukan diambil sebagai informasi menggunakan pendekatan *rule-based* (Alifi & Supangkat, 2016). Selain itu, digunakan fitur tambahan berupa *Part-of-speech* (POS) *Tagging* untuk meningkatkan performa model NER (Rifani et al., 2019). POS *Tagging* diperlukan dalam menjalankan metode *rule-based* karena dapat

digunakan sebagai daftar kamus dan aturan untuk mendeteksi entitas (Nguyen et al., 2016). Aturan yang telah didefinisikan pada *rule-based system* digunakan untuk mengambil informasi lokasi, tanggal, waktu, jenis kendaraan, jenis kecelakaan, faktor penyebab kecelakaan, dan jumlah korban luka maupun meninggal dunia.

Data hasil ekstraksi tidak seluruhnya lengkap sehingga diperlukan metode untuk menangani informasi yang hilang agar dapat dilakukan analisis lebih lanjut. Data yang masih mengandung *missing value* akan ditangani menggunakan dua metode berbeda, yaitu menggunakan metode *deletion* atau menghapus data yang terdapat *missing value* dan yang kedua adalah menggunakan metode imputasi *mode by concept* atau mengisi variabel *missing* menggunakan modus dari variabel yang memiliki konteks yang relevan dengan variabel yang hilang.

Data Preprocessing


Data cleaning dilakukan untuk menyiapkan data dengan menghapus berita dengan *missing content*, menyeragamkan format, dan menghapus data duplikat berdasarkan kesamaan *link* atau URL berita. Kemudian dilakukan *text preprocessing* berupa *case folding*, *tokenizing*, *stopword removal*, dan *stemming*.

- Case folding* digunakan untuk menyamaratakan penggunaan huruf kapital. Pada proses *case folding* karakter-karakter “A”-“Z” yang terdapat pada data diubah kedalam karakter “a”-“z”.
- Tokenizing* adalah proses memecah string masukan menjadi unit-unit yang lebih kecil yang disebut token. Sebagai contoh, tokenisasi dari kalimat “Kecelakaan di jalan tol” akan menghasilkan empat token terpisah, yaitu “Kecelakaan”, “di”, “jalan”, “tol”.
- Stopword* adalah kata umum yang biasanya muncul dalam jumlah besar dan dianggap tidak memiliki makna. Contoh *stopword* dalam bahasa Indonesia adalah “yang”, “dan”, “di”, “dari”, dan sebagainya.
- Stemming* adalah sebuah proses di bidang pemrosesan bahasa alami yang bertujuan untuk menghilangkan infleksi kata sehingga kata-kata tersebut berada dalam bentuk dasarnya. Bentuk dasar yang dihasilkan tidak selalu sama dengan akar kata (*root word*). Misalnya kata “tabrakan”, “tertabrak”, “ditabrak” akan ditransformasi menjadi kata “tabrak”.

Filtering dilakukan dengan tujuan untuk mereduksi data yang tidak relevan dengan topik dan menyeleksi data yang mirip. Dalam mengecek relevansi berita, mulanya Sebagian data diambil dan dikategorikan menjadi dua kategori, “relevan” dan “tidak relevan”, berita yang termasuk dalam kategori “relevan” dilabeli dengan angka “1” dan berita “tidak relevan” dilabeli dengan angka “0”. Kemudian untuk mengkategorikan secara otomatis data dapat menggunakan *Naïve Bayes Classifier Semi-Supervised Learning*. Sementara untuk mengetahui konten yang mirip, dapat digunakan metode *cosine similarity*. *Cosine similarity* dilakukan dengan memvektorisasi konten dengan TF-IDF, kemudian mengukur kemiripan tiap konten dengan nilai *cosine* dan menyimpannya ke dalam matriks. Pasangan berita dikatakan mirip apabila nilai *cosine* > 0.6. Pasangan berita yang mirip dikelompokkan bersama kemudian dihapus dan disisakan berita dengan tanggal unggahan yang paling akhir.

Ekstraksi Informasi

Ekstraksi informasi dilakukan menggunakan NER Bi-LSTM-CNN dengan pendekatan *rule-based* untuk mendapatkan informasi yang dibutuhkan secara rinci. NER digunakan untuk mengidentifikasi dan mengekstraksi informasi kecelakaan dengan mengkategorikan entitas ke dalam kelas-kelas yang telah ditentukan sebelumnya. Kemudian *rule-based system* digunakan untuk mengambil informasi atribut yang diperlukan. Entitas yang diekstraksi pada tahap ini meliputi CAUSE (penyebab kecelakaan), DATE (tanggal), DAY (hari), LOC (lokasi, daerah/tempat selain jalan tol), ORG (organisasi), PER (orang/manusia), SINGLE (jenis kecelakaan), TIME (waktu), TOL (jalan tol), VEHICLE (kendaraan), dan MISC (lain-lain) yang masing-masing diberikan notasi IOB (*Inside*, *Outside*, *Beginning*) untuk menandai urutan. Langkah-langkah yang dilakukan dalam melakukan NER dengan algoritma BiLSTM-CNN dapat dilihat pada Gambar 1.



Gambar 1. Arsitektur Model NER BiLSTM-CNN

Dalam proses NER, yang pertama dilakukan adalah dengan mengambil sebagian data untuk diberikan anotasi secara manual untuk membangun model NER. Kemudian menginisiasi parameter input data pada model NER dengan melakukan proses *embedding* yang terdiri dari *word embedding*, *character embedding*, *case embedding*, dan *POS embedding*. Setelah dilakukan proses *embedding*, kemudian dilakukan penggabungan vektor dari setiap kata dengan *concatenation* (penggabungan sejajar).

- Word embedding* merupakan *input layer* yang memetakan kosakata menjadi bentuk vektor berdimensi tinggi. *Word embedding* yang digunakan adalah *GloVe word embedding vector* berukuran 50 dimensi yang diinisiasi secara acak menggunakan distribusi Uniform dengan interval -0.5 sampai 0.5 (-0.5, 0.5).
- Pada tahap *character embedding*, setiap karakter dalam kata akan diubah menjadi vektor dengan dimensi 30. Proses ini melibatkan pemetaan setiap karakter ke dalam representasi vektor yang spesifik. Untuk memulai, vektor-vektor ini diinisialisasi secara acak dengan menggunakan distribusi Uniform dengan rentang nilai antara -0,5 hingga 0,5 (-0,5, 0,5).
- Representasi karakter diteruskan ke dalam CNN untuk mengekstraksi fitur-fitur karakteristik dari setiap kata. CNN menggunakan lapisan konvolusi untuk mengurangi kompleksitas perhitungan dengan memanfaatkan prinsip *sliding window* dan *weight sharing*.
- Case embedding* digunakan untuk mengidentifikasi jenis huruf (huruf besar atau huruf kecil) pada setiap kosakata dalam dataset. Setiap token merepresentasikan vektor yang mencerminkan kasusnya. Vektor *case embedding* diinisialisasi menggunakan distribusi Uniform dengan rentang nilai antara -0,5 hingga 0,5 (-0,5, 0,5).
- POS embedding* digunakan untuk memetakan kosakata ke dalam *tag POS* yang sesuai. Setiap kata akan diberikan representasi vektor yang mencerminkan *tag POS*-nya. Inisialisasi vektor *POS embedding* dilakukan menggunakan distribusi Uniform dengan rentang nilai antara -0,5 hingga 0,5 (-0,5, 0,5).

Hasil dari penggabungan vektor menggunakan metode *concatenation* diubah menjadi dua vektor terpisah, yang akan menjadi input dalam penerapan rekursi maju dan mundur pada *Bidirectional LSTM*. Rekursi maju dan mundur memungkinkan model untuk memproses informasi kontekstual baik dari konteks sebelumnya (rekursi maju) maupun konteks setelahnya (rekursi mundur) secara simultan. *Dense layer* digunakan untuk menghasilkan prediksi tag terbaik secara berurutan.

Kemudian untuk mengambil informasi yang spesifik digunakan pendekatan *rule-based*. Pendekatan ini memanfaatkan informasi dari fitur-fitur seperti *tag NER*, *tag POS*, dan kamus kosakata untuk memperoleh informasi yang diperlukan. Aturan-aturan dalam *rule-based system* digunakan untuk memeriksa dan mengidentifikasi pola atau kriteria tertentu dalam teks, seperti informasi lokasi, tanggal, waktu, jenis kendaraan, jenis kecelakaan, faktor penyebab kecelakaan, jumlah korban luka, dan jumlah korban meninggal dunia.

Penanganan Missing Value

Keterbatasan informasi yang dapat diekstraksi dari berita *online* dapat menyebabkan kurang lengkapnya data dan menyebabkan adanya *missing value*. Agar dapat melakukan analisis lanjutan, perlu dilakukan penanganan *missing value*, yang dalam penelitian ini menggunakan dua pendekatan.

Pendekatan pertama adalah metode *deletion* atau dengan menghapus data yang terdapat *missing value*. Dalam hal ini, data yang tidak lengkap dihapus dari dataset untuk memastikan bahwa hanya data yang lengkap

yang digunakan dalam analisis lebih lanjut. Meskipun pendekatan ini sederhana, namun dapat memberikan kepastian terhadap kualitas data yang digunakan.

Pendekatan kedua yang digunakan adalah metode *mode by concept*. Metode ini bertujuan untuk menangani *missing value* dengan mengisi nilai yang paling sering muncul (*mode*) untuk setiap atribut atau konsep dalam data. Dengan menggunakan metode *mode by concept*, nilai yang paling umum atau dominan dalam masing-masing atribut digunakan untuk mengisi nilai yang hilang, sehingga karakteristik dan distribusi data yang ada dapat dipertahankan.

Aturan Keputusan Pola Kecelakaan

Untuk membentuk sebuah aturan keputusan, digunakan analisis non parametrik menggunakan algoritma *machine learning* dengan membuat model pohon keputusan (*decision tree*). *Decision tree* digunakan karena proses pada pohon keputusan mirip dengan proses pengambilan keputusan yang dilakukan oleh manusia sehingga lebih mudah untuk diinterpretasikan (Patel & Prajapati, 2018). Selain itu, metode ini juga dapat menangani kumpulan data besar dengan sejumlah besar variabel secara efisien (Li et al., 2019).

Classification and Regression Trees (CART) merupakan salah satu metode atau algoritma pada *decision tree* yang mengklasifikasikan menggunakan algoritma penyekatan rekursif secara biner (Lewis, 2000). CART akan menghasilkan pohon klasifikasi jika variabel respon mempunyai skala kategorik dan akan menghasilkan pohon regresi jika variabel respon berupa data kontinu (Zacharis, 2018).

Saat mengklasifikasikan menggunakan CART, tujuannya adalah membagi kumpulan data menjadi dua bagian dengan menggunakan homogenitas data sebagai kriteria pembagi. Untuk memutuskan atribut mana yang dipisah, CART didasarkan pada nilai *impurity* seperti entropi atau indeks Gini. Pada *node t*, indeks Gini didefinisikan sebagai:

$$Gini(t) = 1 - \sum_{j=0}^1 \left(\frac{n(j|t)}{n(t)} \right)^2 \dots \dots \dots (1)$$

dimana j adalah kelas dari variabel target, $n(j|t)$ adalah jumlah record dari *node t* yang termasuk dalam kelas j , dan $n(t)$ adalah total *record* dalam *node t*. Ketika data dalam sebuah *node* terdistribusi secara merata antara semua kelas, indeks Gini mencapai nilai *impurity* maksimum 0,5. Dalam kasus dimana semua data milik kelas yang sama, *node* memiliki nilai *impurity* minimum dan indeks Gini adalah 0, untuk memutuskan atribut yang akan dipisahkan, algoritma *decision tree* menghitung rata-rata tertimbang dari indeks Gini *node* yang diturunkan.

$$Gini(t)_{split} = \frac{n(t_L)}{n(t)} Gini(t_L) + \frac{n(t_R)}{n(t)} Gini(t_R) \dots \dots \dots (2)$$

dimana t_L dan t_R adalah *child node* kiri dan kanan dari *node t*. Atribut yang meminimalkan nilai $Gini(t)_{split}$ dipilih untuk membagi *node*.

Aturan keputusan yang dibuat menggunakan CART untuk mengetahui pola kejadian kecelakaan berdasarkan fatalitas kejadian kecelakaan menggunakan beberapa variabel, seperti ada tidaknya korban meninggal dunia (Die) sebagai *root node* atau variabel target. Dengan variabel input adalah lokasi (Location), hari (Day), waktu (Time), golongan kendaraan (Class), jenis kecelakaan (Type), dan penyebab kecelakaan (Cause), dan ada tidaknya korban luka (Injury) yang dijelaskan pada Tabel 1.

Tabel 1. Keterangan Variabel dan Atribut *Decision Tree* CART.

Variabel	Keterangan Variabel	Atribut	Keterangan Atribut
Die	Ada tidaknya korban meninggal dunia pada kejadian kecelakaan	Die [Die, No_Die]	Die artinya terdapat korban meninggal dunia pada kejadian kecelakaan, No_Die artinya tidak terdapat korban meninggal dunia pada kejadian kecelakaan
Location	Lokasi kejadian kecelakaan	Location [Tol Cipali, ..., Tol Cipularang]	Kejadian kecelakaan terjadi pada jalan tol tertera
Day	Hari kejadian kecelakaan	Day [Weekday, Weekend]	Weekday terdiri dari hari Senin, Selasa, Rabu, Kamis, dan Jum'at, Weekend terdiri dari hari Sabtu dan Minggu
Time	Waktu kejadian kecelakaan	Time [Siang, Malam]	Siang terdiri dari waktu kejadian pukul 06.00-17.59 WIB, Malam terdiri dari waktu kejadian pukul 18.00-05.59 WIB
Vehicle	Golongan kendaraan yang terlibat dalam kecelakaan	Class_1 [Yes, No] Class_Other [Yes, No]	Kendaraan Class_1 adalah kendaraan golongan I (mobil, bus, pick up, jip, truk kecil), Class_Other adalah kendaraan golongan II-V (truk besar)

Variabel	Keterangan Variabel	Atribut	Keterangan Atribut
Type	Jenis kejadian kecelakaan	Type [Single, Other]	Single artinya kejadian kecelakaan adalah kecelakaan tunggal, Other artinya kejadian kecelakaan adalah kecelakaan ganda, maupun kecelakaan beruntun
Cause	Penyebab kejadian kecelakaan	Cause [Human, Other]	Human artinya faktor penyebab kecelakaan adalah manusia, Other artinya faktor penyebab kecelakaan adalah bukan manusia (prasarana dan lingkungan, kendaraan, dan lainnya)
Injury	Ada tidaknya korban luka pada kejadian kecelakaan	Injury [Injury, No_Injury]	Die artinya terdapat korban luka pada kejadian kecelakaan, No_Die artinya tidak terdapat korban luka pada kejadian kecelakaan

HASIL DAN PEMBAHASAN

Ekstraksi Informasi

Pada pembangunan model NER, mulanya dilakukan POS *Tagging* pada data dengan bantuan *library Flair* pada pemrograman berbahasa *Python*. Kemudian data diambil 30% atau sebanyak 169 artikel yang kemudian dianotasi secara manual. Sampel ini digunakan sebagai acuan untuk melatih dan mengevaluasi model NER. Anotasi diberikan dengan pendekatan IOB (*Inside, Outside, Beginning*), yang menandakan setiap token dalam teks menunjukkan apakah token tersebut merupakan awal entitas bernama, bagian dalam entitas bernama, atau bukan bagian dari entitas bernama sama sekali. Pemberian anotasi IOB dalam pembangunan model NER dimuat pada Tabel 2.

Tabel 2. Pemberian Anotasi pada Pembangunan Model NER

Artikel	Kalimat	Kata	POS	NER
(2)	(3)	(4)	(5)	(6)
971	0	Kecelakaan	NOUN	O
971	0	terjadi	VERB	O
971	0	di	ADP	O
971	0	Tol	PROPN	B-TOL
971	0	Cipularang	PROPN	I-TOL
...	...	...	...	...
1199	2506	mengejar	VERB	O
1199	2506	bus	NOUN	B-VEHICLE
1199	2506	.	PUNC	O

Data dipisahkan ke dalam bentuk *array* per kalimat, dimana setiap kalimat diperlakukan sebagai unit pemrosesan terpisah. Hal ini memberikan keuntungan dalam evaluasi dan penggunaan model NER, karena model dapat fokus pada setiap kalimat secara individu untuk mengenali dan melabeli entitas bernama yang terdapat di dalamnya.

Tabel 3. Evaluasi Model NER BiLSTM-CNN.

NER Tag	Precision	Recall	F1-score
CAUSE	0.38	0.35	0.36
DATE	0.88	0.94	0.91
DAY	0.94	1.00	0.97
LOC	0.83	0.93	0.88
MISC	0.82	0.70	0.76
ORG	0.64	0.58	0.61
PER	0.81	0.89	0.85
SINGLE	0.93	0.88	0.90
TIME	0.93	0.91	0.92
TOL	0.85	0.92	0.89
VEHICLE	0.74	0.86	0.79
Mean	0.78	0.83	0.81


Berdasarkan Tabel 3, model NER BiLSTM-CNN menghasilkan nilai *f1-score* sebesar 81%, nilai *recall* sebesar 83%, dan nilai *precision* sebesar 78%. Kemudian dari hasil klasifikasi menggunakan NER BiLSTM-CNN, atribut hasil ekstraksi diambil sebagai informasi menggunakan pendekatan *rule-based*. Aturan-aturan tersebut digunakan untuk mengidentifikasi dan mendapatkan atribut tertentu dari teks berita, seperti jalan tol, hari, tanggal, waktu, jenis kendaraan, faktor penyebab, jenis kecelakaan, jumlah korban luka, dan jumlah korban meninggal dunia. Pada Tabel 4 ditampilkan contoh hasil ekstraksi informasi pada salah satu konten berita.

Tabel 4. Hasil Ekstraksi Informasi Konten Berita.

Entitas	Informasi
Konten berita	Minibus yang mengangkut rombongan keluarga mengalami kecelakaan di tol Cipali Km 112, Subang, Jawa Barat, Selasa (11/2/2020) dini hari. Satu orang tewas dan 5 orang terluka. Kecelakaan diduga karena sopir tak bisa mengendalikan laju kendaraan.
Jalan tol	Tol Cipali Km 112
Hari	Selasa
Tanggal	11/2/2020
Waktu	Dini hari
Kendaraan	Minibus
Faktor penyebab	Sopir tak bisa mengendalikan laju kendaraan
Jenis kecelakaan	-
Jumlah korban luka	5 (lima)
Jumlah korban meninggal	1 (satu)


Analisis Deskriptif

Dari hasil ekstraksi informasi, kemudian diperiksa kembali kesamaan antar data hasil ekstraksi dan diperoleh data sejumlah 327 kejadian kecelakaan lalu lintas di jalan tol di Provinsi Jawa Barat yang dianggap tunggal, dengan ringkasan dari data adalah sebagai berikut:




Gambar 2. Jumlah Kecelakaan, Korban Meninggal Dunia, dan Korban Luka, Tahun 2020-2022.

Dari gambar 2, dapat dilihat bahwa jumlah kecelakaan dan korban luka selalu naik dari 2020 hingga 2022. Sementara itu, jumlah korban meninggal dunia mengalami penurunan pada tahun 2021 dan kemudian mengalami kenaikan pada tahun 2022. Kemudian pada tahun 2020, rasio korban meninggal dunia per kasus kecelakaan mencapai angka tertinggi yaitu 1,33 korban meninggal dunia per kasus kecelakaan. Ini menunjukkan bahwa dalam setiap kasus kecelakaan pada tahun tersebut, rata-rata terdapat 1,33 korban meninggal dunia. Pada tahun 2021, rasio tersebut mengalami penurunan menjadi 0,88 korban meninggal dunia per kasus kecelakaan, menandakan adanya perbaikan dalam hal penurunan tingkat fatalitas. Namun, pada tahun 2022, meskipun jumlah korban meninggal dunia mengalami kenaikan, rasio korban meninggal dunia per kasus kecelakaan menurun menjadi hanya 0,55 korban meninggal dunia per kasus kecelakaan.



Gambar 3. Jumlah Kecelakaan Berdasarkan Bulan, Tahun 2020-2022.

Dari gambar 3, terlihat bahwa jumlah kejadian kecelakaan tertinggi terjadi pada bulan September 2022 dengan 23 kejadian. Bulan-bulan lain yang juga memiliki jumlah kejadian kecelakaan tinggi adalah Juli 2022 dan Oktober 2022, keduanya dengan 20 kejadian. Di sisi lain, bulan-bulan dengan jumlah kejadian kecelakaan terendah adalah Januari 2020, Mei 2020, Juni 2020, Juli 2020, Februari 2021, dan April 2021, semuanya dengan 2 kejadian. Trend yang dapat diamati adalah bahwa jumlah kejadian kecelakaan cenderung lebih tinggi pada kuartal ke-3 (Juli, Agustus, September) dan ke-4 (Oktober, November, Desember).



Gambar 4. Jumlah Kecelakaan Berdasarkan Jalan Tol.

Dari gambar 4, dapat dilihat bahwa Tol Jagorawi menjadi tol dengan jumlah kejadian kecelakaan paling tinggi, mencapai 109 kejadian. Tol Cipali berada di peringkat kedua dengan 87 kejadian kecelakaan, diikuti oleh Tol Cipularang dengan 72 kejadian kecelakaan. Sementara itu, jumlah kejadian kecelakaan di jalan tol lainnya lebih rendah, dengan total hanya 59 kejadian kecelakaan.

Aturan Keputusan Pola Kecelakaan

Salah satu aspek penting dalam pemodelan *decision tree* adalah penanganan *missing value*. Dalam penelitian ini, digunakan dua pendekatan untuk menangani adanya *missing value*, yaitu menggunakan metode *deletion* dan imputasi. Pendekatan tersebut diaplikasikan pada beberapa dataset untuk mengidentifikasi pendekatan yang paling sesuai, dengan rincian sebagai berikut:


- Menggunakan seluruh data dengan fitur *deletion* sebagai metode penanganan *missing value* dan tanpa jalan tol sebagai atribut (*All data + deletion*).
- Menggunakan seluruh data dengan fitur imputasi *mode by concept* sebagai metode penanganan *missing value* dan tanpa jalan tol sebagai atribut (*All data + imputasi*).

- c. Menggunakan seluruh data dengan fitur *deletion* sebagai metode penanganan *missing value* dan jalan tol sebagai atribut (*All data + deletion + Tol*).
- d. Menggunakan seluruh data dengan fitur imputasi *mode by concept* sebagai metode penanganan *missing value* dan jalan tol sebagai atribut (*All data + imputasi + Tol*).
- e. Menggunakan data tiga tol dengan fatalitas tertinggi dengan fitur *deletion* sebagai metode penanganan *missing value* tanpa dan jalan tol sebagai atribut (*3 Tol + deletion*).
- f. Menggunakan data tiga tol dengan fatalitas tertinggi dengan fitur imputasi *mode by concept* sebagai metode penanganan *missing value* dan tanpa jalan tol sebagai atribut (*3 Tol + imputasi*).
- g. Menggunakan data tiga tol dengan fatalitas tertinggi dengan fitur *deletion* sebagai metode penanganan *missing value* dan jalan tol sebagai atribut (*3 Tol + deletion + Tol*).
- h. Menggunakan data tiga tol dengan fatalitas tertinggi dengan fitur imputasi *mode by concept* sebagai metode penanganan *missing value* dan jalan tol sebagai atribut (*3 Tol + imputasi + Tol*).

Tabel 5. Evaluasi Model CART pada Dataset Berbeda.

Data	F1-score	Accuracy	Precision	Recall
<i>All data + deletion</i>	0.5035	0.6817	0.6270	0.4356
<i>All data + imputasi</i>	0.5772	0.6993	0.6538	0.5382
<i>All data + deletion + Atribut Tol</i>	0.5893	0.7027	0.6361	0.5789
<i>All data + imputasi + Atribut Tol</i>	0.6006	0.6930	0.6255	0.5914
<i>3 tol + deletion</i>	0.5391	0.6867	0.6171	0.4978
<i>3 tol + imputasi</i>	0.6535	0.7339	0.7197	0.6121
<i>3 tol + deletion + Atribut Tol</i>	0.6544	0.7463	0.6916	0.6759
<i>3 tol + imputasi + Atribut Tol</i>	0.6776	0.7549	0.7654	0.6743

Dari kedelapan dataset pada Tabel 5, terdapat satu dataset terpilih yaitu dataset yang menggunakan data tiga tol dengan fatalitas tertinggi dengan fitur imputasi *mode by concept* sebagai metode penanganan *missing value* dan jalan tol sebagai atribut (*3 Tol + imputasi + Tol*). Dalam melakukan analisis menggunakan *decision tree* CART, model dengan dataset ini menghasilkan nilai *f1-score* dan akurasi yang tertinggi dibandingkan jika menggunakan dataset lain, dengan nilai *f1-score* sebesar 67,76% dan akurasi sebesar 75,49%. Oleh karena itu, dataset ini dianggap yang terbaik untuk memodelkan pola kecelakaan menggunakan *decision tree* CART.



Gambar 5. Aturan Keputusan dengan CART.

Dataset ini terdiri dari 268 data yang mencakup informasi tentang kecelakaan di tiga jalan tol, yaitu Tol Cipali dengan 87 kejadian kecelakaan, Tol Cipularang dengan 72 kejadian kecelakaan, dan Tol Jagorawi dengan 109 kejadian kecelakaan. Dari *decision tree* yang terbentuk pada Gambar 5, dapat ditarik beberapa aturan, sebagai berikut:

- a. Location $\Rightarrow$ Tol Jagorawi

Kecelakaan yang terjadi di Tol Jagorawi terdapat peluang adanya fatalitas sebesar 8% dengan support 41%. Artinya, dari 109 kejadian kecelakaan yang terjadi, 8% atau 9 kejadian di antaranya mengakibatkan

- korban meninggal dunia. Selain itu, kecelakaan di Tol Jagorawi juga memiliki support yang cukup besar 41%, yang mengindikasikan bahwa kecelakaan di tol ini cukup sering terjadi dalam dataset.
- b. Location $\Rightarrow$ Tol Cipali, Tol Cipularang; Time $\Rightarrow$ siang; Injury $\Rightarrow$ No_injury;
Kecelakaan yang terjadi di Tol Cipali atau Tol Cipularang pada waktu siang dan kecelakaan tidak mengakibatkan korban luka terdapat peluang adanya fatalitas sebesar 22% dengan support sebesar 13%. Artinya, dari 36 kejadian kecelakaan yang terjadi, 22% atau 8 kejadian di antaranya mengakibatkan korban meninggal dunia.
 - c. Location $\Rightarrow$ Tol Cipali, Tol Cipularang; Time $\Rightarrow$ siang; Injury $\Rightarrow$ Injury; Cause $\Rightarrow$ No_Human;
Kecelakaan yang terjadi di Tol Cipali atau Tol Cipularang pada waktu siang, pada saat kecelakaan terdapat korban luka, dan dengan faktor penyebab bukan manusia terdapat peluang adanya fatalitas sebesar 38% dengan support sebesar 3%. Artinya, dari 8 kejadian kecelakaan yang terjadi, 38% atau 3 kejadian di antaranya mengakibatkan korban meninggal dunia.
 - d. Location $\Rightarrow$ Tol Cipali, Tol Cipularang; Time $\Rightarrow$ siang; Injury $\Rightarrow$ Injury; Cause $\Rightarrow$ Human; day $\Rightarrow$ Weekend;
Kecelakaan yang terjadi di Tol Cipali atau Tol Cipularang pada waktu siang, pada saat kecelakaan terdapat korban luka, dengan faktor penyebab adalah manusia, dan terjadi pada akhir pekan terdapat peluang adanya fatalitas sebesar 40% dengan support sebesar 4%. Artinya, dari 10 kejadian kecelakaan yang terjadi, 40% atau 4 kejadian di antaranya mengakibatkan korban meninggal dunia.
 - e. Location $\Rightarrow$ Tol Cipali, Tol Cipularang; Time $\Rightarrow$ siang; Injury $\Rightarrow$ Injury; Cause $\Rightarrow$ Human; day $\Rightarrow$ Weekday;
Kecelakaan yang terjadi di Tol Cipali atau Tol Cipularang pada waktu siang, pada saat kecelakaan terdapat korban luka, dengan faktor penyebab adalah manusia, dan terjadi pada akhir pekan terdapat peluang adanya fatalitas sebesar 72% dengan support sebesar 7%. Artinya, dari 18 kejadian kecelakaan yang terjadi, 72% atau 13 kejadian di antaranya mengakibatkan korban meninggal dunia.
 - f. Location $\Rightarrow$ Tol Cipali, Tol Cipularang; Time $\Rightarrow$ malam;
Kecelakaan yang terjadi di Tol Cipali atau Tol Cipularang pada waktu malam terdapat peluang adanya fatalitas sebesar 85% dengan support sebesar 32%. Artinya, dari 87 kejadian kecelakaan yang terjadi, 72% atau 74 kejadian di antaranya mengakibatkan korban meninggal dunia. Dengan sebesar 32% menunjukkan bahwa kejadian kecelakaan dengan pola ini cukup sering terjadi. Ditemukan pula fakta bahwa jenis kecelakaan dan golongan kendaraan tidak membedakan fatalitas pada kejadian kecelakaan yang terjadi.

KESIMPULAN

Hasil penelitian menunjukkan bahwa ekstraksi informasi kecelakaan lalu lintas di jalan tol di Provinsi Jawa Barat dari artikel berita detik.com dilakukan menggunakan model NER Bi-LSTM-CNN yang menghasilkan data akhir sebanyak 327 kejadian kecelakaan. Hasil penelitian menunjukkan bahwa CART dapat memodelkan pola kejadian kecelakaan dengan cukup baik. Model CART yang terbaik ditemukan dengan menggunakan dataset yang hanya mencakup data tiga tol dengan fatalitas tertinggi dengan fitur imputasi *mode by concept* sebagai metode penanganan *missing value* dan jalan tol sebagai atribut (3 Tol + imputasi + Tol). Model ini mendapatkan nilai *f1-score* sebesar 67,76% dan akurasi sebesar 75,49%.

Lebih lanjut, ditemukan bahwa terdapat kemiripan pola kecelakaan lalu lintas antara jalan Tol Cipali dan Cipularang berdasarkan struktur pohon (*tree*) yang terbentuk dari model CART tersebut. Ketika kedua tol tersebut digabungkan, terdapat kemungkinan tinggi terjadinya kematian dalam kecelakaan, mencapai 41%. Oleh karena itu, diperlukan perhatian lebih dalam pengelolaan keselamatan di kedua jalan tol tersebut. Selain itu, temuan menunjukkan bahwa kejadian kecelakaan yang menyebabkan kematian cenderung terjadi pada waktu malam tanpa adanya pengaruh variabel lain. Hal ini menunjukkan adanya potensi risiko yang lebih tinggi pada saat malam hari mengenai fatalitas kecelakaan. Sedangkan pada siang hari fatalitas cenderung dipengaruhi oleh variabel lain, seperti faktor penyebab kecelakaan yang juga cenderung disebabkan oleh manusia dan hari kejadian yang lebih sering terjadi pada hari kerja.

DAFTAR PUSTAKA

- Alifi, M. R., & Supangkat, S. H. (2016). Information Extraction for Traffic Congestion in Social Network. 2016 International Conference on ICT For Smart Society (ICISS), 53–58.
- BPJT. (2022). Laporan Tahunan Badan Pengatur Jalan Tol.
- Chiu, J. P. C., & Nichols, E. (2016). Named Entity Recognition with Bidirectional LSTM-CNNs. Transactions of the Association for Computational Linguistics, 4, 357–370.
- Gloria. (2021, November 7). Pakar UGM Sebut Empat Faktor Penyebab Kecelakaan di Jalan Tol.
- Lewis, R. J. (2000). An Introduction to Classification and Regression Tree (CART) Analysis.

- Li, J., He, J., Liu, Z., Zhang, H., & Zhang, C. (2019). Traffic accident analysis based on C4.5 algorithm in WEKA. *MATEC Web of Conferences*, 272, 01035.
- Mulia, F. R., & Widowati, E. (2021). Kecelakaan Lalu Lintas Jalan Tol Ruas Batang-Semarang Berdasarkan Karakteristik Faktor Penyebab Kecelakaan Tahun 2019. *Indonesian Journal of Public Health and Nutrition (IJPHN)*, 1(2), 214–222.
- Nguyen, D. Q., Nguyen, D. Q., Pham, D. D., & Pham, S. B. (2016). A Robust Transformation-Based Learning Approach Using Ripple Down Rules for Part-of-Speech Tagging. *AI Communications*, 29(3), 409–422.
- Patel, H. H., & Prajapati, P. (2018). Study and Analysis of Decision Tree Based Classification Algorithms. *International Journal of Computer Sciences and Engineering*, 6(10), 74–78.
- Rayanti, D. (2022, December 5). Kecelakaan di Cipali Paling Tinggi Sedunia. *Detik.Com*. <https://oto.detik.com/berita/d-6440776/tol-cipali-paling-mematikan-di-dunia-apa-sebabnya>
- Rifani, R., Bijaksana, M. A., & Asror, I. (2019). Named Entity Recognition for an Indonesian Based Language Tweet using Multinomial Naive Bayes Classifier. *Indonesia Journal on Computing (Indo-JC)*, 4(2), 119–126.
- Setyabudi, B. (2021). Kajian Peran Tempat Istirahat (Rest Area) Kendaraan Guna Menurunkan Tingkat Kecelakaan dan Kelelahan Pengemudi pada Jalan Tol Ruas Jakarta-Cikampek. *Warta Penelitian Perhubungan*, 23(4), 371-387.
- Susanti, E., & Mustofa, K. (2015). Ekstraksi Informasi Halaman Web Menggunakan Pendekatan Bootstrapping pada Ontology-Based Information Extraction. *IJCCS*, 9(2), 111–120.
- Undang-Undang No 2 Tahun 2022 tentang Jalan. (2022). UU No Tahun 2022.
- Zacharis, N. Z. (2018). Classification and Regression Trees (CART) for Predictive Modeling in Blended Learning. *International Journal of Intelligent Systems and Applications*, 10(3), 1–9.

